

Segmentacija Kupaca - RFM Analiza

K-means clustering za marketinske strategije

Datum: 29.05.2026

1. Uvod i cilj projekta

Projektni zadatak bio je izvršiti segmentaciju kupaca na temelju njihovog ponašanja pri kupnji. Glavni cilj bio je identificirati različite grupe kupaca kako bi se mogle razviti ciljane marketinske strategije. Problem koji rješavamo: tvrtke često tretiraju sve kupce jednako, što dovodi do neuinkovitog marketinga i gubitka prilika za povećanje prodaje. Segmentacijom kupaca možemo personalizirati komunikaciju, optimizirati marketinski budžet i povećati zadovoljstvo kupaca.

2. Podaci korišteni u analizi

Korišten je Superstore dataset koji sadrži 9.994 transakcije. Podaci obuhvaćaju razdoblje od 2014. do 2017. godine. Ukupno je analizirano 793 jedinstvenih kupaca. Za svakog kupca izračunate su tri RFM metrike:

- Recency (nedavnost): broj dana od zadnje kupnje
- Frequency (učestalost): ukupan broj narudžbi
- Monetary (monetarna vrijednost): ukupna potrošnja u EUR

3. Metodologija

Koristene su dvije metode grupiranja (clustering): K-means i DBSCAN.

K-means:

- Algoritam koji grupira podatke u unaprijed zadani broj grupa (k)
- Svaka grupa ima svoje središte (centroid)
- Cilj: minimizirati udaljenost unutar grupa
- Prednost: jednostavan, brz, lako interpretabilan

DBSCAN:


- Algoritam temeljen na gustoci podataka
- Ne zahtijeva unaprijed zadani broj grupa
- Automatski detektira izuzetke (outliere)
- Nedostatak: kompleksniji za interpretaciju

Odabrali smo K-means kao primarnu metodu jer proizvodi čiste, lako interpretabilne segmente koji su razumljivi marketinskim timovima. Optimalni broj grupa (k=3) određen je Elbow metodom i Silhouette skorom.

4. Distribucija RFM metrika


Grafovi prikazuju distribuciju triju RFM metrika među 793 kupca. Vidljivo je da većina kupaca ima relativno

nisku ucestalost i potrosnju, dok mali broj kupaca ostvaruje visoku potrosnju (desno asimetrična distribucija).




5. Određivanje optimalnog broja grupa

Elbow metoda (lijevo) i Silhouette skor (desno) korišteni su za određivanje optimalnog broja grupa. Elbow graf pokazuje "lakat" kod $k=3$, a Silhouette skor ima najveću vrijednost također kod $k=3$. Stoga je odabrano $k=3$ kao optimalan broj segmenata.



6. Karakteristike segmenata



7. Rezultati segmentacije

K-means algoritam identificirao je tri segmenta kupaca:

SEGMENT 0 - STANDARDNI KUPCI (453 kupca, 57.1% baze)

- Prosjecna nedavnost: 88 dana
- Prosjecna ucestalost: 10.2 narudzbe
- Prosjecna potrosnja: 1.862 EUR
- Karakteristike: Povremeni ali konzistentni kupci
- Marketinska strategija: Redovita komunikacija, sezonske promocije, edukativni sadrzaj


SEGMENT 1 - LOJALNI KUPCI (230 kupaca, 29.0% baze)

- Prosjecna nedavnost: 80 dana
- Prosjecna ucestalost: 19.6 narudzbi
- Prosjecna potrosnja: 5.550 EUR
- Karakteristike: Redoviti kupci, visoka potrosnja
- Marketinska strategija: Newsletter sa posebnim ponudama, cross-sell i upsell, referral program


SEGMENT 2 - POVREMENI KUPCI (110 kupaca, 13.9% baze)

- Prosjecna nedavnost: 535 dana
- Prosjecna ucestalost: 7.7 narudzbi
- Prosjecna potrosnja: 1.612 EUR
- Karakteristike: Niska angaziranost, dugo nisu kupovali
- Marketinska strategija: Ciljane promocije, povrat napustenih kosarica, sezonski podsjetnici

8. Distribucija segmenata

Customer Segments Distribution**9. Udio u prihodu po segmentima**



Segment 1 (lojalni kupci) generira 55.6% ukupnog prihoda unatoc tome sto cini samo 29% baze kupaca. To potvrđuje Paretovo nacelo (80/20) - mali broj kupaca donosi vecinu prihoda. Preporuka: fokusirati marketinske aktivnosti na zadrzavanje i nagrađivanje lojalnih kupaca.

Revenue Contribution by Segment**10. Usporedba metoda: K-means vs DBSCAN**

Kao alternativna metoda testiran je DBSCAN algoritam. Rezultati:

- DBSCAN je identificirao samo 1 klaster (vecina kupaca)
- Detektirano je 27 izuzetaka (outliera) sto cini 3.4% baze
- Razlog: DBSCAN slabije radi na podacima s razlicitim gustocama

ZAKLJUCAK: K-means je bolji izbor za ovaj dataset jer proizvodi 3 cista, interpretabilna segmenta koja su razumljiva marketinskim timovima. DBSCAN je koristan za detekciju izuzetaka, ali ne daje prakticne segmente za marketing.



11. Zaključak i preporuke

Segmentacija kupaca uspješno je provedena korištenjem RFM analize i K-means clusteringa. Identificirana su tri jasno definirana segmenta s različitim karakteristikama i potrebama.

Preporuke za klijenta:

1. Fokusrati marketinske aktivnosti na Segment 1 (lojalni kupci) - oni donose najviše prihoda
2. Razviti program vjernosti i ekskluzivne pogodnosti za najvrijednije kupce
3. Aktivacijske kampanje za Segment 2 (povremeni kupci) - povratne ponude i "vratite nam se" akcije
4. Nurturing kampanje za Segment 0 (standardni kupci) - povećati učestalost kupnje
5. Automatizirati segmentaciju na mjesečnoj bazi za praćenje promjena

12. Kontakt

Antoni Situm

Email: chisquare.analiza@gmail.com

CHI-SQUARE - Data Science za poduzeca

Usluge: Predviđanje prodaje, Segmentacija kupaca, Detekcija anomalija